Análisis exploratorio del corpus AG News

Preprocesamiento del texto y diagnóstico del corpus

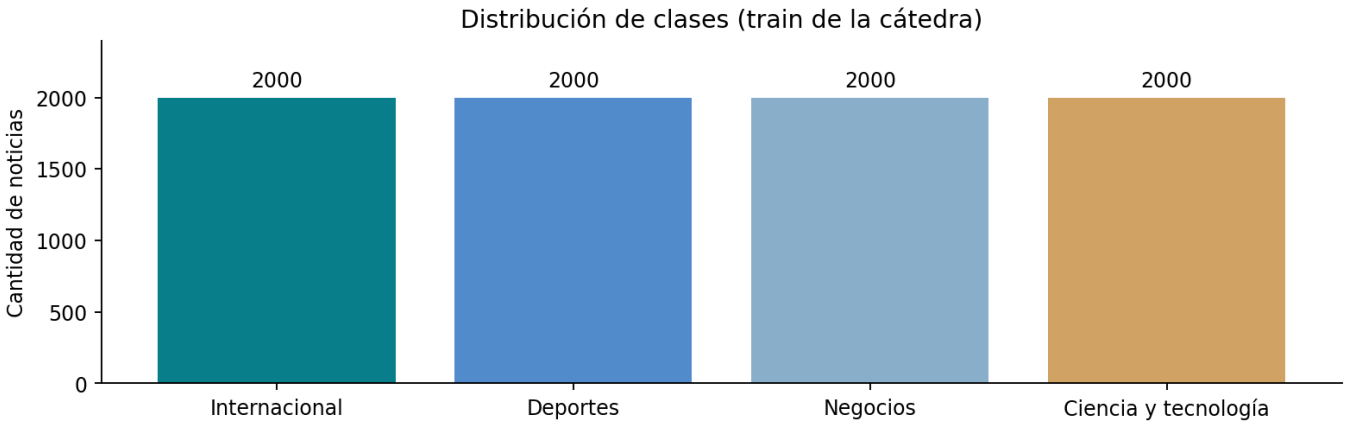
AG News · Corpus en inglés de la cátedra · Conjunto de entrenamiento

Tokenización y lematización con SpaCy (en_core_web_sm).

1. Corpus y distribución de clases

Se trabajó con la muestra de AG News provista por la cátedra. Cada registro contiene el texto de una noticia (**text**) y su categoría (**label**). Todas las estadísticas del informe se calcularon sobre el conjunto de entrenamiento; las noticias de prueba se mantuvieron fuera del análisis.

Indicador	Valor
Noticias de entrenamiento	8.000
Noticias de prueba (sin analizar)	2.000
Valores nulos en train	0
Textos duplicados exactos	0
Clases	World, Sports, Business, Sci_Tech
Balance	Perfectamente balanceado (2.000 documentos por clase)



Las cuatro categorías están representadas por igual. Esto facilita la comparación inicial de modelos, aunque sigue siendo necesario analizar los errores y las métricas de cada clase por separado.

2. Preparación y normalización del texto

1. **Limpieza:** se normalizaron entidades HTML, incluidas codificaciones incompletas presentes en el corpus, y se retiraron etiquetas, enlaces, direcciones de correo y marcas editoriales. Después se aplicaron minúsculas y se unificaron los espacios.

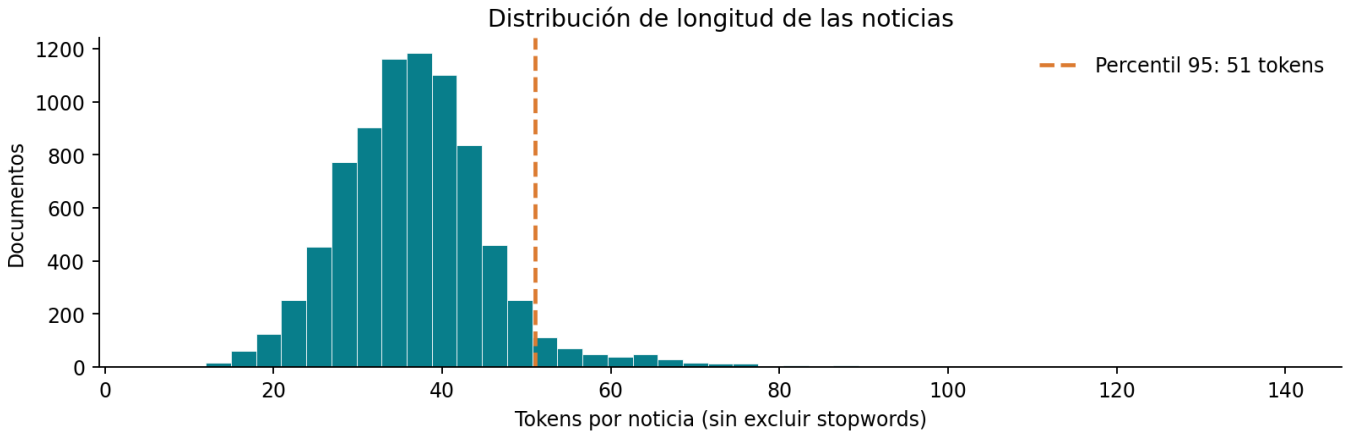
2. **Tokenización:** se dividieron las noticias en palabras con SpaCy y se conservaron los tokens alfabéticos.

3. **Lematización:** se utilizó el modelo inglés en_core_web_sm para unificar variantes flexivas.

4. **Palabras vacías:** se mantuvieron al medir longitudes y frecuencias, pero se excluyeron al calcular N-gramas. Se conservaron las negaciones no, not y nor, que pueden modificar el sentido de una frase.

5. **Separación de datos:** ninguna estadística ni vocabulario se estimó utilizando el archivo de prueba.

3. Longitud de las noticias

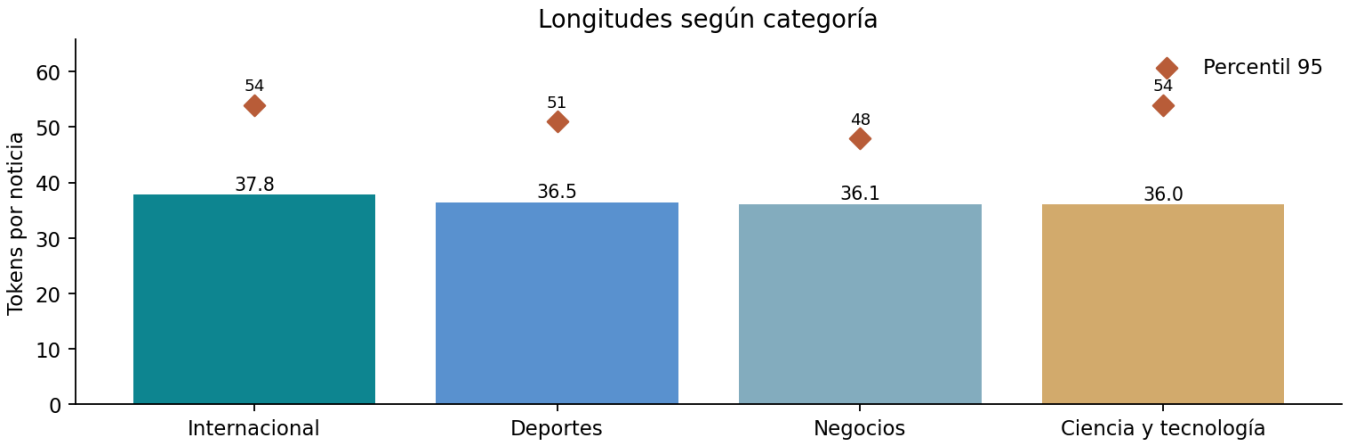


Métrica	Tokens por documento
Promedio	36.6
Mediana	36
Percentil 90	47
Percentil 95	51
Máximo	140

El percentil 95 es de **51 tokens**: el 95 % de las noticias tiene esa longitud o menos después de la normalización. Es una referencia razonable para la longitud máxima de un modelo basado en palabras. Si se utiliza BERT u otro Transformer, deberá recalcularse con su tokenizador de subpalabras.

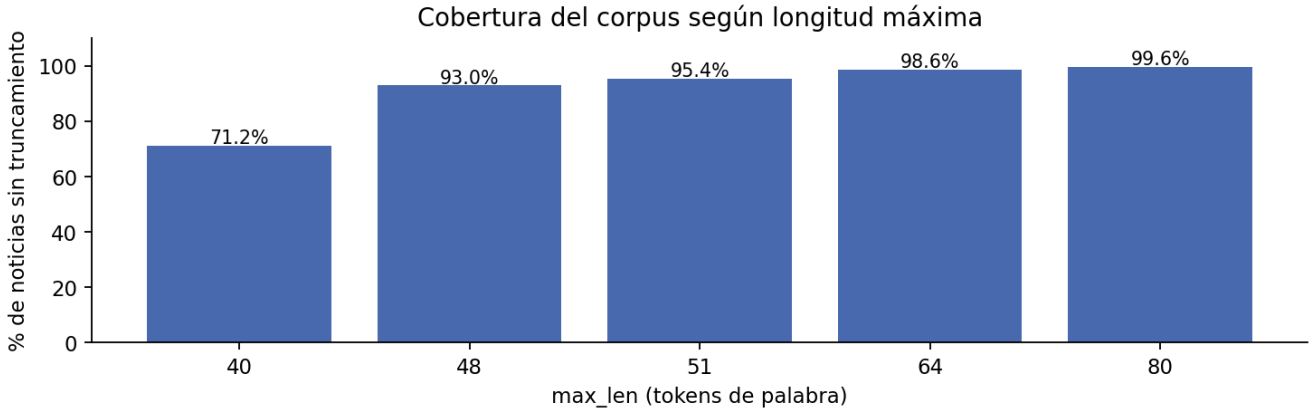
4. Diferencias de longitud entre categorías

Un conjunto equilibrado en cantidad de documentos no necesariamente es homogéneo en longitud. Se compararon las cuatro clases por separado, utilizando tokens lematizados antes de retirar palabras vacías.



Categoría	Promedio	P95	Superan max_len
Internacional	37.8	54	122 (6.1%)
Deportes	36.5	51	92 (4.6%)
Negocios	36.1	48	37 (1.8%)
Ciencia y tecnología	36.0	54	117 (5.9%)

Cobertura de distintas longitudes máximas



Con **max_len = 51**, se conserva completa aproximadamente el 95 % de las noticias. El resto requerirá truncamiento si no se adopta una ventana mayor. Una longitud mayor disminuye el recorte, pero incrementa el costo del procesamiento. Esta comparación corresponde a **palabras**, no a tokens WordPiece.

5. Calidad del texto y decisión de limpieza

La muestra está libre de nulos, pero eso no implica ausencia de ruido textual. Antes del modelado se inspeccionaron los patrones de codificación y los elementos editoriales que podrían introducir términos artificiales.

Incidencia en el texto original	Noticias	Porcentaje
Entidades HTML incompletas	2.360	29.50%
Etiquetas HTML	0	0.00%
Enlaces explícitos	135	1.69%

Criterios adoptados

• La decodificación HTML se aplica **antes** de eliminar la puntuación. Así se evita que fragmentos de entidades terminen entre las palabras más repetidas.

• Se estandarizan minúsculas y espacios, pero se documenta que la remoción de números, símbolos y puntuación puede perder información relevante en algunas tareas.

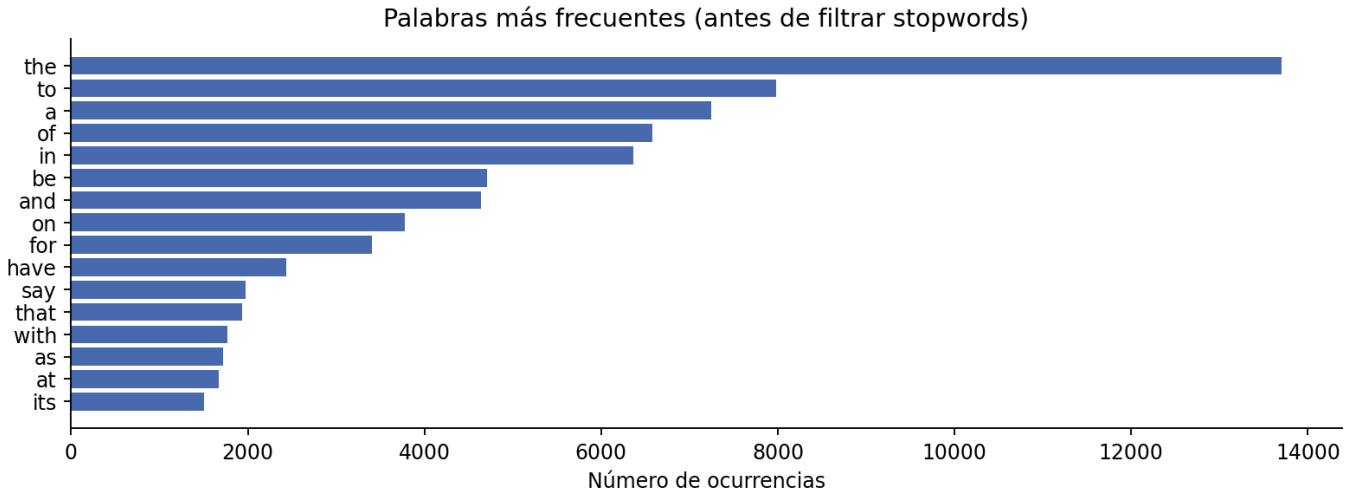
• Las stopwords se conservan para la descripción de longitud. Para estudiar expresiones temáticas se filtran, manteniendo no, not y nor. La lista de stopwords no se aplica de forma automática a futuros Transformers.

• Los N-gramas se construyen sobre el texto filtrado; al retirar palabras funcionales, algunas combinaciones no eran contiguas en la noticia original.

Como control adicional, tras la normalización aparece **1** coincidencia textual completa que no figuraba entre los duplicados exactos originales. Este indicio debe revisarse antes de construir una partición interna de entrenamiento y validación; no demuestra por sí solo que existan noticias idénticas en significado.

Un diagnóstico de calidad permite fundamentar cada transformación y evitar que el modelo aprenda características del formato editorial en lugar del tema periodístico.

6. Frecuencias del vocabulario



Entre las 50 palabras más frecuentes, **37** figuran en la lista de stopwords de SpaCy (74%). Este predominio justifica excluirlas del recuento de expresiones temáticas, pero conservarlas al estudiar la longitud original del texto.

Top 50 de palabras (frecuencia en train)

#	Palabra	Frecuencia	#	Palabra	Frecuencia
1	the	13698	26	not	804
2	to	7976	27	over	803
3	a	7242	28	their	733
4	of	6578	29	up	730
5	in	6365	30	he	727
6	be	4705	31	two	675
7	and	4637	32	first	673
8	on	3774	33	company	651
9	for	3410	34	world	609
10	have	2435	35	but	598
11	say	1975	36	one	582
12	that	1932	37	win	579
13	with	1771	38	more	578
14	as	1720	39	they	577
15	at	1669	40	game	554
16	its	1501	41	us	551
17	it	1437	42	report	551
18	new	1433	43	ap	548
19	by	1357	44	out	545
20	from	1221	45	this	543
21	an	1194	46	oil	519
22	will	1050	47	monday	518
23	year	969	48	usa	516
24	after	947	49	wednesday	505
25	his	940	50	thursday	502

7. Bigramas frecuentes

Los bigramas se calcularon con CountVectorizer sobre el texto lematizado y sin palabras vacías, excepto las negaciones. Al retirar palabras funcionales, algunos pares no eran adyacentes en el texto original.

Posición	Bigrama	Ocurrencias
1	new york	419
2	oil price	197
3	united states	167
4	prime minister	139
5	official say	115
6	say thursday	102
7	say monday	101
8	red sox	98
9	say tuesday	98
10	los angeles	96
11	san francisco	96
12	president bush	93
13	say wednesday	90
14	say friday	88
15	year old	88
16	mobile phone	72
17	wall street	71
18	microsoft corp	70
19	world cup	69
20	chief executive	67

Interpretación

Se destacan expresiones como new york, oil price, prime minister, mobile phone, relacionadas con lugares, economía, política o tecnología. En conjunto muestran que el corpus combina nombres propios con vocabulario especializado; habrá que examinar su peso por clase antes de incorporarlas al modelo.

La frecuencia de una expresión no garantiza que sea útil para clasificar: su valor dependerá de cómo se distribuya entre las cuatro categorías.

8. Trigramas frecuentes

Se aplicó el mismo procesamiento y filtrado que en los bigramas.

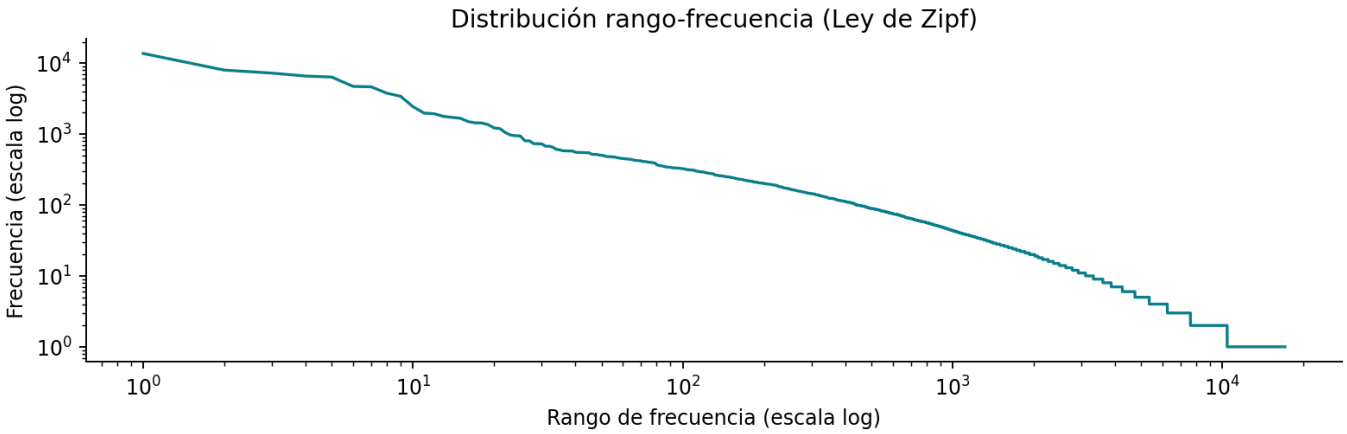
Posición	Trigrama	Ocurrencias
1	new york usa	43
2	boston red sox	37
3	high oil price	27
4	prime minister ariel	26
5	minister ariel sharon	25
6	secretary state colin	22
7	state colin powell	22
8	new york yankees	21
9	president george bush	21
10	president vladimir putin	21
11	crude oil price	20
12	international space station	18
13	minister tony blair	17
14	prime minister tony	17
15	los angeles dodger	16
16	st louis cardinal	16
17	initial public offering	15
18	mart stores inc	15
19	oil price rise	15
20	osama bin laden	15

Interpretación

Expresiones como boston red sox, crude oil price, international space station describen entidades y asuntos más específicos que los bigramas. Su menor frecuencia es esperable: al aumentar la longitud de las secuencias, disminuyen las repeticiones exactas y crece la dispersión.

En la siguiente etapa se podrá estudiar qué expresiones son verdaderamente discriminativas para cada categoría, por ejemplo mediante TF-IDF.

9. Distribución léxica



Indicador	Resultado
Vocabulario distinto	17.060
Tokens totales (sin quitar stopwords)	292.749
Tipos con frecuencia 1 (hapax)	6.652 (39.0%)
Riqueza léxica, tipos/tokens	0.058

La elevada proporción de términos con frecuencia uno confirma una cola larga: abundan nombres propios y expresiones poco repetidas. Esta dispersión puede afectar a modelos basados en vocabularios completos; para TF-IDF convendrá controlar frecuencia mínima y regularización.

10. Vocabulario distintivo por categoría

Se comparó la **frecuencia documental** de cada término dentro de su categoría respecto de las otras tres. La razón calculada mide concentración temática en entrenamiento, no desempeño predictivo ni importancia causal. Solo se muestran términos que aparecen en al menos 40 noticias de la clase.

Internacional

Término	Documentos de clase	Razón vs. otras clases
militant	101	608.8×
palestinian	88	530.8×
gaza	64	386.9×
soldier	58	350.9×
sudan	55	332.9×

Deportes

Término	Documentos de clase	Razón vs. otras clases
nfl	63	380.9×
quarterback	58	350.9×
tournament	56	338.9×
touchdown	56	338.9×
coach	119	238.9×

Negocios

Término	Documentos de clase	Razón vs. otras clases
insurance	43	260.9×
bankruptcy	49	33.0×
quarterly	70	32.5×
crude	79	28.1×
profit	180	24.1×

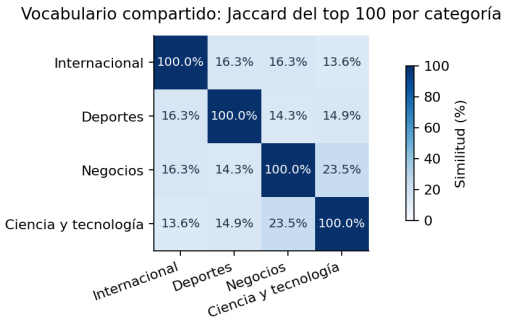
Ciencia y tecnología

Término	Documentos de clase	Razón vs. otras clases
nasa	72	434.9×
linux	50	101.0×
user	120	65.7×
server	64	55.3×
download	44	53.4×

Las noticias comparten vocabulario transversal, pero estas concentraciones sugieren señales temáticas útiles para empezar la clasificación. La pertinencia real se comprobará con validación independiente.

11. Solapamiento temático y preparación del modelado

Además de la frecuencia global, se compararon los 100 términos de mayor frecuencia documental de cada categoría. El índice de Jaccard señala cuánto vocabulario comparten, aunque no debe interpretarse como una matriz de errores del clasificador.



Decisiones metodológicas para los próximos módulos

• **Representación:** comenzar con TF-IDF y comparar después con embeddings y Transformers sobre el mismo corpus.

• **Control de dimensionalidad:** evaluar vocabulario mínimo, regularización y tratamiento de términos poco frecuentes debido a la cola larga.

• **Secuencia:** usar como referencia el percentil 95 de palabras; volver a calcular longitudes para el tokenizador subword del modelo final.

• **Validación:** ajustar vocabulario, transformadores y parámetros solo con entrenamiento y validación; conservar el test para la evaluación final.

• **Interpretación:** observar métricas por clase y una matriz de confusión para analizar solapamientos semánticos que el EDA no puede resolver por sí solo.

12. Conclusiones

El conjunto de entrenamiento de AG News reúne 8.000 noticias, con una distribución uniforme entre World, Sports, Business y Sci_Tech. No se detectaron registros nulos ni duplicados exactos. Sin embargo, 2.360 noticias contenían fragmentos de codificación HTML que podían convertirse en términos artificiales, por lo que fue necesario normalizarlos antes de tokenizar y lematizar. Las noticias tienen una mediana de 36 tokens. El percentil 95 es 51, que permitiría conservar completas el 95.4 % de las secuencias de palabras. La distribución de longitud no es idéntica entre clases; World presenta un percentil 95 de 54 tokens, lo que requiere atender posibles diferencias de truncamiento. El vocabulario contiene 17.060 lemas distintos y 6.652 aparecen una sola vez. La cola larga aconseja controlar la dimensionalidad y la frecuencia mínima en representaciones basadas en palabras. Los N-gramas y términos distintivos evidencian temas periodísticos reconocibles, pero su frecuencia no prueba por sí sola utilidad predictiva. Para los siguientes módulos se recomienda comparar TF-IDF con modelos neuronales, aplicar validación por categoría y recalcular la longitud con el tokenizador subword correspondiente. El conjunto de prueba se mantendrá aislado hasta la evaluación final.

Datos y reproducibilidad

Fuente: AG News, muestra académica provista por Coderhouse (8.000 noticias de entrenamiento). Herramientas: pandas, scikit-learn, SpaCy 3.8.16 y matplotlib. Procesamiento: en_core_web_sm (modelo de inglés SpaCy). El archivo de prueba se reservó para evaluaciones posteriores.