Clasificación de noticias con LoRA

Pre-entrega 4. Fine-tuning eficiente de un Transformer sobre AG News. Se compara el modelo neuronal con el clasificador TF-IDF del módulo anterior, conservando la misma muestra académica y el mismo conjunto oficial de prueba.

1. Arquitectura y elección del modelo

Se utiliza **DistilBERT base uncased**, un Transformer preentrenado en inglés. Se eligió porque las noticias del corpus están en inglés y su tamaño permite ajustar adaptadores en una GPU gratuita. El modelo produce cuatro etiquetas: Business, Sci_Tech, Sports y World. La elección se apoya en Sanh et al. (2019), sin asumir que sea superior al baseline [1].

Característica	Configuración aplicada
Arquitectura	distilbert-base-uncased
Datos	AG News · 8.000 entrenamiento · 2.000 prueba
Tokenización	WordPiece, padding dinámico, truncamiento
Longitud máxima	128 sub-tokens
Hardware	Tesla T4 (14.56 GiB de VRAM)

2. Configuración PEFT-LoRA

Se inyectan adaptadores en las proyecciones de **query** y **value** de los seis bloques de atención. Las matrices preentrenadas quedan congeladas. Las capas pre_classifier y classifier sí se entrenan y guardan, porque deben aprender las cuatro categorías de este experimento [2, 3].

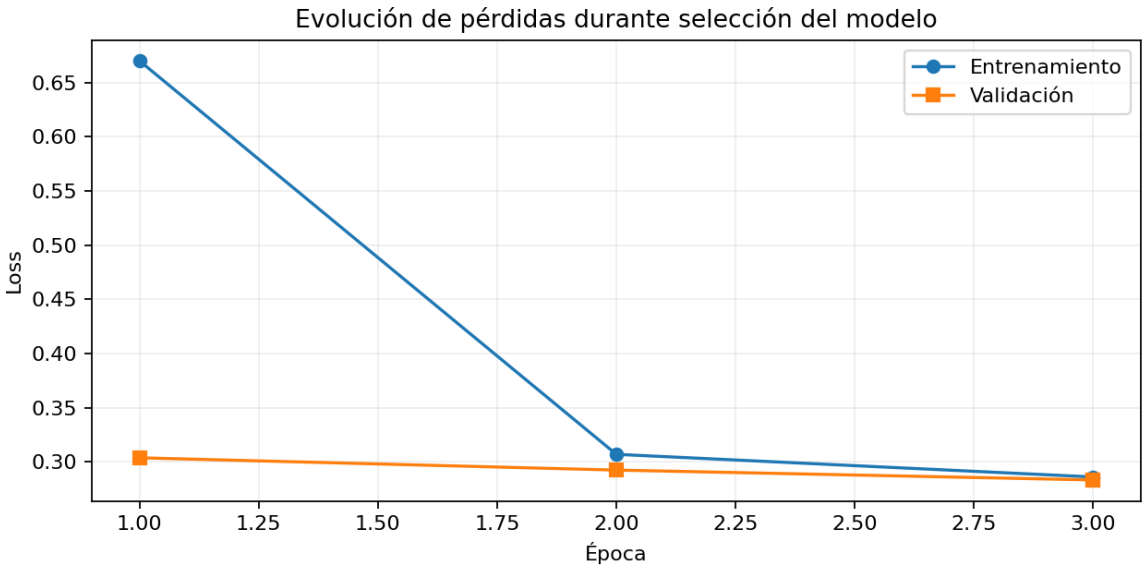
Parámetro	Valor registrado
Rango y escala	r=8; alpha=16; dropout=0.05
Módulos objetivo	q_lin, v_lin
Parámetros del modelo original	66.956.548
Parámetros totales con LoRA	67.697.672
Parámetros entrenables	741.124
Porcentaje entrenable	1,09 %
Solo matrices LoRA	147.456
Cabeza y otros módulos entrenables	593.668

El porcentaje incluye adaptadores y la cabeza clasificadora (inicializada para cuatro clases). No equivale a porcentaje de VRAM: activaciones y estados del optimizador también consumen recursos.

3. Entrenamiento, validación y eficiencia

Se separaron estratificadamente 6.400 noticias para ajuste y 1.600 para validación, sin textos normalizados duplicados entre particiones. Se seleccionó la época por F1-macro de validación. El archivo de prueba no participó en esa selección.

Indicador	Valor medido
Tasa de aprendizaje	0.0001
Batch y acumulación	16 por dispositivo; x2
Épocas máximas / seleccionada	3 / 3
Loss de entrenamiento (mejor época)	0.2860
Loss de validación (mejor época)	0.2833
Loss de reajuste final (8.000)	0.3968
F1-macro de validación	90,54 %
Tiempo de selección	0.7 minutos
Tiempo de ajuste final	0.8 minutos
Tiempo total de entrenamiento	1.5 minutos
Pico de memoria PyTorch	0.67 GiB asignados

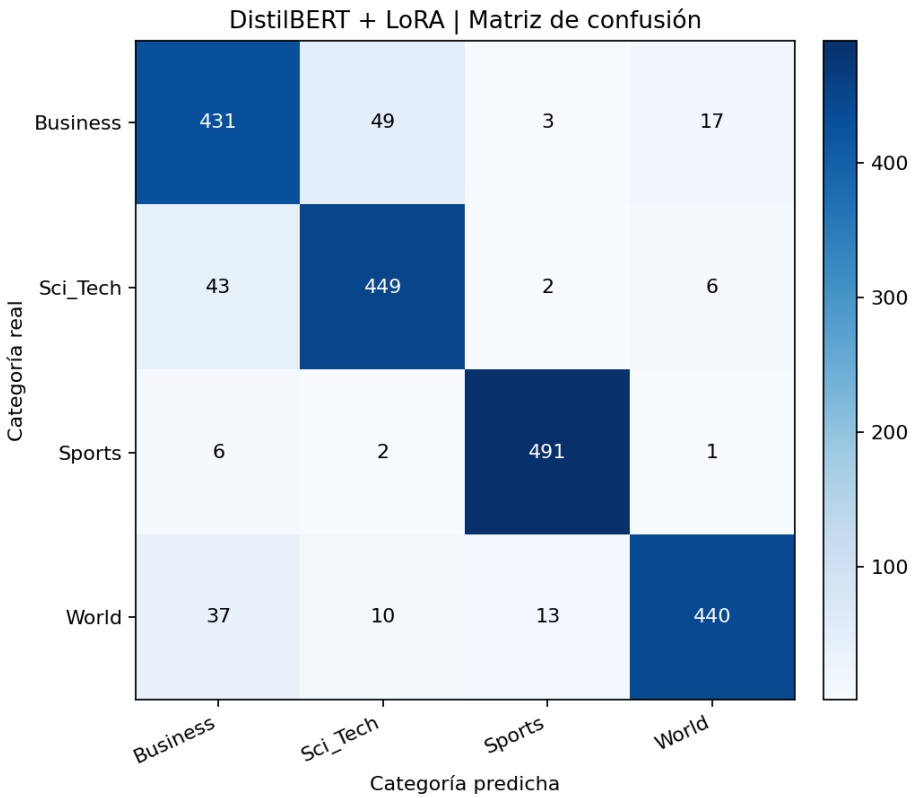


Las curvas muestran la fase de selección por validación. La evaluación de test utiliza un nuevo ajuste sobre las 8.000 noticias, durante el número de épocas seleccionado.

4. Evaluación y comparación con el baseline

Los resultados siguientes corresponden a las mismas 2.000 noticias oficiales de test. El vectorizador TF-IDF del Checkpoint 3 nunca se ajustó sobre esas noticias.

Métrica	TF-IDF + Naive Bayes	DistilBERT + LoRA
Precision macro	89,14 %	90,67 %
Recall macro	89,10 %	90,55 %
F1-macro	89,11 %	90,57 %
Accuracy	89,10 %	90,55 %



Las cifras de TF-IDF se leen directamente del reporte registrado en el Checkpoint 3. Las cifras de LoRA y la matriz de confusión proceden de la ejecución actual.

Desempeño por categoría

Categoría	Precision	Recall	F1
Business	83,37 %	86,20 %	84,76 %
Sci_Tech	88,04 %	89,80 %	88,91 %
Sports	96,46 %	98,20 %	97,32 %
World	94,83 %	88,00 %	91,29 %

La confusión más frecuente fue Business como Sci_Tech (49 noticias).

5. Interpretación y conclusiones técnicas

LoRA aumentó el F1-macro en 1.46 puntos porcentuales. Se observa una mejora en esta muestra, aunque su conveniencia operativa depende del tiempo y de la memoria exigida por el entrenamiento.

Se preservó la separación entre entrenamiento, validación y prueba. La pérdida de entrenamiento y la de validación permiten evaluar la convergencia; la matriz de confusión permite revisar qué categorías presentan errores sistemáticos. La comparación por F1-macro es apropiada porque las cuatro categorías están equilibradas [5]. Diferencias pequeñas no prueban por sí solas superioridad estadística.

El ajuste con LoRA requirió **1.5 minutos** en **Tesla T4**. Sin una medición del baseline clásico en el mismo hardware, no sería riguroso informar una aceleración cuantitativa. Asimismo, la reducción de parámetros entrenables no significa que el consumo total de memoria disminuya en la misma proporción.

Alcance: este experimento se limita a la muestra académica de AG News. El test ya fue evaluado en checkpoints anteriores y no representa un conjunto externo nunca consultado. No se ensayó un fine-tuning completo como control, por lo que no se infiere una ventaja causal de LoRA frente a actualizar todos los pesos. Las métricas pueden variar con semillas, bibliotecas y GPU.

6. Datos y reproducibilidad

Componente	Versión / procedencia
Dataset	CSV originales de AG News facilitados por la cátedra
PyTorch	2.14.1+cu130
Transformers	4.57.3
PEFT	0.17.1
Datasets	4.4.1
Semilla	42
Test	Sin ajustar LoRA ni seleccionar hiperparámetros con él

Las versiones, los parámetros y los identificadores SHA-256 de los archivos CSV se registran en outputs/resumen_lora.json.

7. Referencias bibliográficas y técnicas

[1] Sanh, V. et al. (2019). DistilBERT, a distilled version of BERT. https://arxiv.org/abs/1910.01108

[2] Hu, E. J. et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. https://arxiv.org/abs/2106.09685

[3] Hugging Face. Documentación PEFT y LoRA. https://huggingface.co/docs/peft/package_reference/lora

[4] Hugging Face. Trainer / TrainingArguments. https://huggingface.co/docs/transformers/main_classes/trainer

[5] Scikit-learn. Métrica F1 para clasificación multiclase. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html